

Single Value Decomposition

SVD

Lema. Toda matriz A , com dimensões $n \times d$, admite uma fatoração $A = UDV^T$.

U é uma matriz com n linhas e r colunas
(r dimensão de A)

D é uma matriz diagonal $r \times r$;

V é uma matriz com d linhas e r colunas;

U e V são ortonormais

SVD: Exemplo

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \underbrace{\begin{bmatrix} .13 & .02 & -.01 \\ .41 & .07 & -.03 \\ .55 & .09 & -.04 \\ .68 & .11 & -.05 \\ .15 & -.59 & .65 \\ .07 & -.73 & -.67 \\ .07 & -.29 & .32 \end{bmatrix}}_U \underbrace{\begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} .56 & .59 & .56 & .09 & .09 \\ .12 & -.02 & .12 & -.69 & -.69 \\ .40 & -.80 & .40 & .09 & .09 \end{bmatrix}}_{V^T}$$

SVD: Motivação

Lema. Toda matriz A , com dimensões $n \times d$, admite uma fatoração $A = UDV^T$

Aplicações

Enxergando A como uma matriz de dados (e.g. cada linha como um dado) temos aplicações em

- Compressão/ visualização
- Ranking
- Clustering

SVD: Interpretação

	Matrix	Star Wars	Casablanca	Titanic
Joe	1	1	1	0
Jim	3	3	3	0
John	4	4	4	0
Jack	5	5	5	0
Jill	0	0	0	4
Jenny	0	0	0	5
Jane	0	0	0	2

Figure 11.6: Ratings of movies by users

SVD: Interpretação

	Matrix	Star Wars	Casablanca	Titanic
Joe	1	1	1	0
Jim	3	3	3	0
John	4	4	4	0
Jack	5	5	5	0
Jill	0	0	0	4
Jenny	0	0	0	5
Jane	0	0	0	2

Figure 11.6: Ratings of movies by users

- Garotos gostam de Sci-Fi
- Meninas gostam de romance

SVD: Interpretação

Hipótese

- O rating de um usuário u para um filme f pode ser explicado pelo *perfil* de u (gosto em relação aos diferentes gêneros) e pelo perfil do filme f (aderência em relação aos diferentes gêneros)
- Gêneros não precisam ser conhecidos/escolhidos a priori

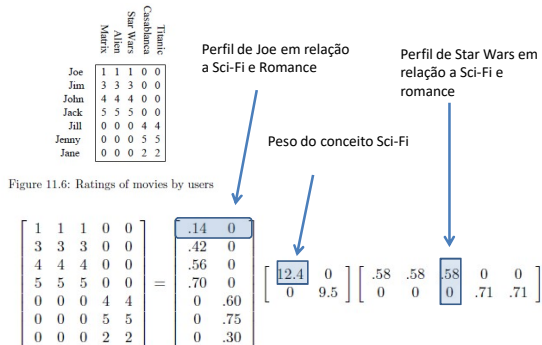
SVD: Interpretação

	Matrix	Star Wars	Casablanca	Titanic
Joe	1	1	1	0
Jim	3	3	3	0
John	4	4	4	0
Jack	5	5	5	0
Jill	0	0	0	4
Jenny	0	0	0	5
Jane	0	0	0	2

Figure 11.6: Ratings of movies by users

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 0 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} .14 & 0 \\ .42 & 0 \\ .56 & 0 \\ .70 & 0 \\ 0 & .60 \\ 0 & .75 \\ 0 & .30 \end{bmatrix} \begin{bmatrix} 12.4 & 0 \\ 0 & 9.5 \end{bmatrix} \begin{bmatrix} .58 & .58 & .58 & 0 & 0 \\ 0 & 0 & 0 & .71 & .71 \end{bmatrix}$$

SVD: Interpretação



SVD: Interpretação

Exemplo com ratings mais misturados

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} .13 & .02 & -.01 \\ .41 & .07 & -.03 \\ .55 & .09 & -.04 \\ .68 & .11 & -.05 \\ .15 & -.59 & .65 \\ .07 & -.73 & -.67 \\ .07 & -.29 & .32 \end{bmatrix} \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix} \begin{bmatrix} .56 & .59 & .56 & .09 & .09 \\ .12 & -.02 & .12 & -.69 & -.69 \\ .40 & -.80 & .40 & .09 & .09 \end{bmatrix}$$

$U \quad \Sigma \quad V^T$

SVD: Interpretação

Se A está contido em um subespaço de dimensão r então temos que $A = UDV^T$ e

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

- v_i é a i-ésima direção 'mais importante' de A
- u_i são os componentes dos pontos de A na direção v_i
- $\sigma_i = D(i,i)$ é usado para dar um peso a direção v_i

SVD: interpretação

Se truncarmos a soma abaixo em k termos conseguimos aproximações/versões compactas da matriz de dados A

$$A \approx \sum_{i=1}^k \sigma_i u_i v_i^T.$$

SVD: Redução de dimensionalidade

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.13 & 0.02 & -0.01 \\ 0.41 & 0.07 & -0.03 \\ 0.55 & 0.09 & -0.04 \\ 0.68 & 0.11 & -0.05 \\ 0.15 & -0.59 & 0.65 \\ 0.07 & -0.73 & -0.67 \\ 0.07 & -0.29 & 0.32 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & -0.09 \end{bmatrix}$$

J. Leskovec, A. Rajaraman, J. Ullman
Mining of Massive Datasets
<http://www.mmds.org>

SVD: Redução de dimensionalidade

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.13 & 0.02 & -0.01 \\ 0.41 & 0.07 & -0.03 \\ 0.55 & 0.09 & -0.04 \\ 0.68 & 0.11 & -0.05 \\ 0.15 & -0.59 & 0.65 \\ 0.07 & -0.73 & -0.67 \\ 0.07 & -0.29 & 0.32 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & \text{X}3 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & -0.09 \end{bmatrix}$$

J. Leskovec, A. Rajaraman, J. Ullman
Mining of Massive Datasets
<http://www.mmds.org>

SVD: Redução de dimensionalidade

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} \approx \begin{bmatrix} 0.13 & 0.02 & -0.01 \\ 0.41 & 0.07 & -0.03 \\ 0.55 & 0.09 & -0.04 \\ 0.68 & 0.11 & -0.05 \\ 0.15 & -0.59 & 0.65 \\ 0.07 & -0.73 & -0.67 \\ 0.07 & -0.29 & 0.32 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & \text{X}3 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & -0.09 \end{bmatrix}$$

J. Leskovec, A. Rajaraman, J. Ullman
Mining of Massive Datasets
<http://www.mmds.org>

SVD: Redução de dimensionalidade

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} \approx \begin{bmatrix} 0.13 & 0.02 & -0.01 \\ 0.41 & 0.07 & -0.03 \\ 0.55 & 0.09 & -0.04 \\ 0.68 & 0.11 & -0.05 \\ 0.15 & -0.59 & 0.65 \\ 0.07 & -0.73 & -0.67 \\ 0.07 & -0.29 & 0.32 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & \text{X}3 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & -0.09 \end{bmatrix}$$

J. Leskovec, A. Rajaraman, J. Ullman
Mining of Massive Datasets
<http://www.mmds.org>

SVD: Redução de dimensionalidade

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} \approx \begin{bmatrix} 0.13 & 0.02 \\ 0.41 & 0.07 \\ 0.55 & 0.09 \\ 0.68 & 0.11 \\ 0.15 & -0.59 \\ 0.07 & -0.73 \\ 0.07 & -0.29 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 \\ 0 & 9.5 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \end{bmatrix}$$

J. Leskovec, A. Rajaraman, J. Ullman:
Mining of Massive Datasets,
<http://www.mmds.org>

17

SVD: Redução de dimensionalidade


$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} \approx \begin{bmatrix} 0.92 & 0.95 & 0.92 & 0.01 & 0.01 \\ 2.91 & 3.01 & 2.91 & -0.01 & -0.01 \\ 3.90 & 4.04 & 3.90 & 0.01 & 0.01 \\ 4.82 & 5.00 & 4.82 & 0.03 & 0.03 \\ 0.70 & 0.53 & 0.70 & 4.11 & 4.11 \\ -0.69 & 1.34 & -0.69 & 4.78 & 4.78 \\ 0.32 & 0.23 & 0.32 & 2.01 & 2.01 \end{bmatrix}$$

J. Leskovec, A. Rajaraman, J. Ullman:
Mining of Massive Datasets,
<http://www.mmds.org>

18

SVD: Construção

- Qual o conjunto de k direções que melhor *'aproxima/representa'* um conjunto de n pontos em \mathbb{R}^d ?




SVD: Construção

- Qual o conjunto de k direções que melhor *'aproxima/representa'* um conjunto de n pontos em \mathbb{R}^d ?
- Qualidade da aproximação
 - Soma do quadrado das distâncias dos pontos ao hiperplano gerado pelas direções (deve ser minimizada)
 - Soma dos quadrados das projeções no subespaço gerado pelas direções (deve ser maximizada)

SVD: Construção

- Com qual qualidade o vetor unitário \mathbf{v} representa um ponto \mathbf{x}_i em \mathbb{R}^d ?



- Maximizar o quadrado da norma da projeção é equivalente a minimizar o quadrado da distância perpendicular a \mathbf{v}

SVD: Construção

Qual conjunto de k direções (vetores unitários) que melhor representa A ?

SVD: Construção

Método guloso (número de direções fixas)

- Encontrar vetor unitário \mathbf{v}_1 tal que $|\mathbf{A}\mathbf{v}_1|$ é maximizado
- Enquanto $i < k$ definir \mathbf{v}_{i+1} como o vetor unitário ortogonal a $\mathbf{v}_1, \dots, \mathbf{v}_i$ tal que

$$|\mathbf{A}\mathbf{v}_{i+1}| \geq |\mathbf{A}\mathbf{v}|$$
 para todo \mathbf{v} ortogonal a $\mathbf{v}_1, \dots, \mathbf{v}_i$

SVD: Construção

Método guloso (todas as direções)

- Encontrar vetor unitário \mathbf{v}_1 tal que $|\mathbf{A}\mathbf{v}_1|$ é maximizado
- Enquanto $|\mathbf{A}\mathbf{v}_i| > 0$ definir \mathbf{v}_{i+1} como o vetor unitário ortogonal a $\mathbf{v}_1, \dots, \mathbf{v}_i$ tal que

$$|\mathbf{A}\mathbf{v}_{i+1}| \geq |\mathbf{A}\mathbf{v}|$$
 para todo \mathbf{v} ortogonal a $\mathbf{v}_1, \dots, \mathbf{v}_i$. Incrementar i
- Definir r como i

SVD: Construção

Propriedade. Ao término do procedimento todos os n pontos da matriz A pertencem ao subespaço V_r gerado pelas direções v_1, \dots, v_r

Prova. Os pontos a que não pertencem a V_r podem ser escritos como

$$a = v_a + v',$$

onde v_a pertence a V_r e v' é ortogonal a V_r

Neste caso $av' > 0$ para todo ponto a que não está em V_r . Logo, teríamos $|Av'| > 0$. Portanto, o algoritmo não teria parado

SVD: Construção

Processo guloso leva a melhor representação?

SVD: Construção

Definição. v_i é i -ésimo **vetor singular a direita** da matriz A

SVD: Construção

Teorema. Seja A uma matriz $n \times d$ com vetores singulares v_1, \dots, v_r . Para $1 \leq k \leq r$, o espaço V_k gerado por v_1, \dots, v_k é o espaço k -dimensional que maximiza a soma dos quadrados das projeções dos n pontos

Prova

- Para $k=1$, segue da definição do método.
- Passo de Indução: Se V_k é ótimo para $\dim k$ então V_{k+1} é ótimo para $\dim k+1$

SVD: Construção

Prova (cont'd)

Seja W um subespaço ótimo de dim $k+1$ e seja w_{k+1} um vetor de W ortogonal a V_k

Seja w_1, \dots, w_{k+1} uma base ortonormal para W tal que w_{k+1} é ortogonal a V_k

SVD: Construção

Prova (cont'd)

Por hipótese

$$|Aw_1|^2 + \dots + |Aw_k|^2 \leq |Av_1|^2 + \dots + |Av_k|^2$$

Além disso, por construção

$$|Aw_{k+1}|^2 \leq |Av_{k+1}|^2$$

Somando as desigualdades provamos o resultado

SVD: Construção

Observação. Av_i é a lista dos comprimentos das projeções dos pontos na direção v_i

Definição. O i -ésimo **valor singular** da matriz A é $\sigma_i = |Av_i|$

SVD: Construção

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 0 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} .14 & 0 \\ .42 & 0 \\ .56 & 0 \\ .70 & 0 \\ 0 & .60 \\ 0 & .75 \\ 0 & .30 \end{bmatrix} \begin{bmatrix} \sigma_1 & & & & \\ 12.4 & 0 & & & \\ 0 & 9.5 & & & \end{bmatrix} \begin{bmatrix} v_1 & & & & \\ .58 & .58 & .58 & 0 & 0 \\ 0 & 0 & 0 & .71 & .71 \end{bmatrix}$$

Exemplo

- Se v_1 corresponde a Sci-Fi então
 $\sigma_1 = |Av_1|$ é o peso de Sci-Fi

SVD: Construção

- 5 pontos em R^5

$$A = \begin{bmatrix} 2 & 0 & 8 & 6 & 0 \\ 1 & 6 & 0 & 1 & 7 \\ 5 & 0 & 7 & 4 & 0 \\ 7 & 0 & 8 & 5 & 0 \\ 0 & 10 & 0 & 0 & 7 \end{bmatrix}$$

- Os valores singulares da matriz acima são 17.92, 15.17, 3.56, 1.98, 0.35

SVD: Construção

- σ_i pode ser vista como a componente de A na direção v_i
- Para essa interpretação fazer sentido deve ser possível recuperar o conteúdo da matriz A a partir dos valores singulares

SVD

Propriedade. Seja a_i é a i -ésima linha da matriz A. Então

$$\sum_{j=1}^n |a_{ij}|^2 = \sum_{j=1}^n \sum_{i=1}^r (a_{ij} \cdot v_i)^2 = \sum_{i=1}^r \sum_{j=1}^n (a_{ij} \cdot v_i)^2 = \sum_{i=1}^r |Av_i|^2 = \sum_{i=1}^r \sigma_i^2(A).$$

- A primeira igualdade abaixo decorre de que todo vetor a_i pode ser escrita como uma combinação linear dos vetores ortonormais v_1, \dots, v_r
- A terceira e quarta igualdade seguem das definições

SVD

- σ_i dá uma idéia da variância capturada pela direção v_i

$$A = \begin{bmatrix} 2 & 0 & 8 & 6 & 0 \\ 1 & 6 & 0 & 1 & 7 \\ 5 & 0 & 7 & 4 & 0 \\ 7 & 0 & 8 & 5 & 0 \\ 0 & 10 & 0 & 0 & 7 \end{bmatrix}$$

- Os valores singulares da matriz acima são 17.92, 15.17, 3.56, 1.98, 0.35
- Os dois componentes principais já explicam 97% da variância: $(17.92^2 + 15.17^2)/564$

SVD

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.13 & 0.02 & -0.01 \\ 0.41 & 0.07 & -0.03 \\ 0.55 & 0.09 & -0.04 \\ 0.68 & 0.11 & -0.05 \\ 0.15 & -0.59 & 0.65 \\ 0.07 & -0.73 & -0.67 \\ 0.07 & -0.29 & 0.32 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & 0.09 \end{bmatrix}$$

- Os valores singulares da a esquerda são 12.4, 9.5 e 1.3.
- O primeiro valor corresponde a 62.5% da variância
- Os dois primeiros correspondem a 99.3% da variância

SVD

Definição. Seja $u_i = Av_i / |Av_i|$. O conjunto de vetores u_1, \dots, u_r são os **vetores singulares a esquerda** da matriz A

SVD: Construção

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 0 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} .14 \\ .42 \\ .56 \\ .70 \\ 0 \\ 0 \\ 0 \end{bmatrix} \begin{bmatrix} 12.4 & 0 \\ 0 & 9.5 \end{bmatrix} \begin{bmatrix} .58 & .58 & .58 & 0 & 0 \\ 0 & 0 & 0 & .71 & .71 \end{bmatrix}$$

u_1 v_1

Exemplo

- Se v_1 corresponde a Sci-Fi então
 - u_1 : são os valores dos usuários em relação a Sci-Fi

SVD

Lema. Os vetores u_1, \dots, u_r formam uma base ortonormal

SVD

Teorema. $A=UDV^T$

A: matriz de dados com n linhas e d colunas

U: matriz com n linhas e r colunas em que as colunas são os vetores singulares a esquerda,

D: matriz diagonal de dimensão (rxr) formada pelos valores singulares

V: é a matriz com d linhas e r colunas em que as colunas são os vetores singulares a direita

SVD

Lema auxiliar. Se $Av=Bv$ para todo vetor v então $A=B$

SVD

Teorema. $A=UDV^T$

Prova.

Por causa do lema, basta mostrar que $Av=(UDV^T)v$ para todo vetor v . Para uma direção principal v_j

$$\left(\sum_{i=1}^r \sigma_i u_i v_i^T \right) v_j = \sigma_j u_j = A v_j$$

A primeira igualdade segue da orthonormalidade dos vetores v_j e a segunda da definição de u_j

SVD

Teorema. $A=UDV^T$

Prova (cont'd).

Se v' é ortogonal a V_r então

$$A v' = (UDV^T) v' = 0$$

Como qualquer vetor v pode ser escrito como combinação linear dos vetores em V_r somado a um vetor ortogonal a V_r o resultado segue.

Best k rank approximation

Seja

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

a aproximação para matriz A dada pelas k primeiras direções (vetores singulares)

Best k rank approximation

Lema (3.5). As linhas de A_k são as projeções dos pontos (linhas de A) no subespaço V_k gerado pelas k direções principais v_1, \dots, v_k

Prova. Como os v_i 's formam uma base ortonormal, a projeção do ponto a em V_k é dada por

$$\sum_{i=1}^k (a \cdot v_i) v_i^T.$$

Portanto, a projeção das linhas da matriz A é dada por

$$\sum_{i=1}^k A v_i v_i^T = \sum_{i=1}^k \sigma_i u_i v_i^T = A_k.$$

Best k rank approximation

Definição: Para uma matriz C a norma $\|C\|_F$ (norma de Frobenius) é a soma dos quadrados das entradas da matriz.

Best k rank approximation

Teorema. Para qualquer matriz B de rank no máximo k temos

$$\|A - A_k\|_F \leq \|A - B\|_F$$

Prova (sketch)

- Seja B uma matriz que minimiza $\|A - B\|_F$
- Seja V o subespaço gerado pelas linhas de B. Temos que cada linha de B é a projeção de A em V, caso contrário trocando as linhas de B pelas projeções das linhas de A em V diminuiríamos

$$\|A - B\|_F.$$

Best k rank approximation

Teorema. Para qualquer matriz B de rank no máximo k temos

$$\|A - A_k\|_F \leq \|A - B\|_F$$

Prova (sketch)

Segue do Teorema (análise do guloso) que

$$\|A_k\|_F \geq \|B\|_F.$$

Como

$$\|A - A_k\|_F + \|A_k\|_F = \|A\|_F$$

e

$$\|A - B\|_F + \|B\|_F = \|A\|_F$$

temos que

$$\|A - A_k\|_F \leq \|A - B\|_F$$

Best k rank approximation

Interpretação/Consequência

- A matriz A_k provê a melhor representação possível dos n pontos em termos de erro quadrático.
- Se tentarmos representar os n pontos de A em um subespaço de $\dim \leq k$ o erro quadrático será maior ou igual ao de A_k

SVD: Método de potências

Como calcular a decomposição SVD?

SVD: Método de potências

Seja $B = A^T A$. Temos que

$$\begin{aligned} B &= A^T A = \left(\sum_i \sigma_i \mathbf{v}_i \mathbf{u}_i^T \right) \left(\sum_j \sigma_j \mathbf{u}_j \mathbf{v}_j^T \right) \\ &= \sum_{i,j} \sigma_i \sigma_j \mathbf{v}_i (\mathbf{u}_i^T \cdot \mathbf{u}_j) \mathbf{v}_j^T = \sum_i \sigma_i^2 \mathbf{v}_i \mathbf{v}_i^T. \end{aligned}$$

SVD: Método de potências

Seja $B=A^T A$. Possível mostrar que

$$B^k = \sum_{i=1}^r \sigma_i^{2k} v_i v_i^T.$$

Note que os valores singulares de $B^{k/2}$ são

$$\sigma_1^k, \dots, \sigma_r^k$$

Portanto,

$$\|B^{k/2}\|_F = \sigma_1^{2k} + \dots + \sigma_r^{2k}$$

SVD: Método de potências

Note que por construção $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$

Se $\sigma_1 > \sigma_2$

$$\frac{1}{\sigma_1^{2k}} B^k \rightarrow v_1 v_1^T.$$

e

$$\frac{B^k}{\|B^{k/2}\|_F} \rightarrow v_1 v_1^T$$

Para encontrar v_1 basta avaliar B^k , para k 'grande' e normalizar uma linha da matriz

$$\frac{B^k}{\|B^{k/2}\|_F}$$

SVD: Método de potências

Complexidade

- Convergência do método depende de $\sigma_1 - \sigma_2$
- Método envolve multiplicação de matrizes, pode ser caro computacionalmente

Exemplo

- A tem tamanho $10^8 \times 10^8$ com 10^9 entradas não nulas (esparsa)
- Ax tem tamanho 10^{16} e não é esparsa. Inviável!

SVD: Método de potências

1. Seja (v_1, v_2, \dots, v_d) uma base ortonormal para \mathbb{R}^d obtida estendendo a base v_1, v_2, \dots, v_r formada pelos vetores singulares. Além disso, seja $x = c_1 v_1 + c_2 v_2 + \dots + c_d v_d$ com $c_1 > 0$
2. Se $\sigma_1 > \sigma_2$ então $B^k x$ converge para $\sigma_1^{2k} c_1 v_1$
3. Como sabemos que v_1 tem norma 1, podemos obter v_1 normalizando $\sigma_1^{2k} c_1 v_1$
4. Para calcular $B^k x$ fazemos $Bx = A^T(Ax)$ e $B^k x = A^T(AB^{k-1}x)$
5. Multiplicação entre matrizes são evitadas
 - Apenas multiplicamos matrizes por vetores $O(nd)$

SVD: Método de potências

Entrada: Matriz A de dimensões $n \times d$

Saída: vetor de dimensão d

1. Escolha um vetor aleatório x com norma 1 utilizando uma distribuição gaussiana

2. Repita

$$x_{old} \leftarrow x$$

$$x \leftarrow A^T(Ax)$$

$$y \leftarrow x \text{ normalizado ; } y_{old} \leftarrow x_{old} \text{ normalizado}$$

Até que $|y - y_{old}| < \text{err}$

3. Devolva y

SVD: Método de potências

Propriedades do método

1. Se o maior valor singular for maior que o segundo maior singular de A então o método converge para v_1
2. Se o maior valor singular for igual ao segundo maior valor singular o método converge para um vetor no espaço de gerado pelas direções principais associadas aos 'maiores' valores singulares (Teorema 3.11 e Lema 3.12 de FDS)

SVD: Método de potências

1. Método apresentado apenas permite obter v_1

2. Para obter v_{k+1} dado que já obtemos v_1, v_2, \dots, v_k

utilizar o método anterior em $A - A_k$, onde

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$